Universidad Rafael Landivar
Inteligencia Artificial
Sección 01
Ing. Max Cerna

DOCUMENTACIÓN PROYECTO NO. 1

Karla Alejandra Palacios Escobar – 1173219

Guatemala, 27 de abril de 2026

CONTENIDO

Introducción 3

Definición del Problema y Objetivos 4

- **Problema** 4
- **Objetivos Generales** 4
- **Objetivos Específicos** 4

Descripción del DataSet utilizado 5

- **Categorías del DataSet** 5

Descripción del preprocesamiento aplicado 6

- **Pasos aplicados** 6
- **Justificación de Stemming** 6
- **Construcción del Vocabulario** 6

Explicación matemática del algoritmo Naïve Bayes, Laplace Smoothing y suma de logaritmos. 7

- **Naive Bayes** 7
- **Probabilidad a Priori P(c)** 7
- **Laplace Smoothing** 7
- **Suma de Logaritmos** 7

Evaluación y Métricas 8

- **K-Folds Cross Validation** 8
- **Definición de Métricas** 8
- **Resultados por Clase** 9
- **Matriz de Confusión Análisis** 10

Diagramas 11

- **Arquitectura de la solución** 11
- **Diagrama de caso de uso** 11
- **Diagrama de Flujo General** 12
- **Diagrama de Componentes** 13
- **Diagrama de Secuencias** 13

Página Principal 14

- **Vista inicial** 14

Terminal 15

- **Modelo Entrenado** 15
- **Métricas** 15

Introducción

En la actualidad, las empresas reciben miles de solicitudes de soporte al cliente diariamente a través de distintos canales digitales. Clasificar manualmente cada una de estas solicitudes al departamento correcto representa un proceso lento, costoso y propenso a errores humanos. Es aquí donde la Inteligencia Artificial ofrece una solución concreta y eficiente.

El presente proyecto tiene como objetivo desarrollar un clasificador de texto basado en el algoritmo Naive Bayes, capaz de categorizar automáticamente solicitudes de soporte al cliente en once categorías distintas.

El sistema presenta una simulación de un portal de mesa de ayuda donde los usuarios ingresan sus solicitudes y el modelo las clasifica automáticamente, permitiendo que sean dirigidas al departamento correcto sin intervención humana.

En el presente no se utilizaron herramientas que automaticen el proceso, en este proyecto se implementó cada etapa manualmente: desde el preprocesamiento del texto, la construcción del vocabulario mediante Bag of Words, el cálculo de probabilidades con Laplace Smoothing y el uso de logaritmos para evitar underflow numérico, hasta la evaluación del modelo con K-Folds Cross Validation.

Definición del Problema y Objetivos

Problema

Las empresas reciben múltiples solicitudes de soporte al cliente de manera recurrente a través de distintos canales. Clasificar manualmente cada solicitud al departamento correcto es un proceso lento y propenso a errores. La solución propuesta es un sistema de clasificación automática que, dado el texto de una solicitud, determine a qué categoría pertenece.

Objetivos Generales

- Aplicar los conceptos de clasificación de texto vistos en el curso.
- Implementar manualmente el algoritmo Naive Bayes
- Construir una aplicación web funcional que clasifique solicitudes.

Objetivos Específicos

- Preprocesar el texto de un dataset para limpiar y normalizar los datos.
- Construir un vocabulario mediante Bag of Words.
- Evaluar el modelo utilizando K-Folds Cross Validation con K=5.
- Guardar el modelo entrenado para su reutilización.
- Desarrollar una interfaz web para clasificar solicitudes en tiempo real.

Descripción del DataSet utilizado

Se utilizó el dataset Bitext Customer Support LLM Chatbot Training Dataset, disponible en Hugging Face:

https://huggingface.co/datasets/bitext/Bitext-customer-support-llm-chatbot-training-dataset

Característica	Descripción
Total de instancias	26,872 solicitudes
Número de categorías	11 categorías
Campo de texto	Instruction
Campo de etiqueta	Category

Categorías del DataSet

- ACCOUNT — Problemas con la cuenta del usuario
- CANCEL — Cancelación de órdenes
- CONTACT — Solicitudes de contacto con soporte
- DELIVERY — Seguimiento de entregas
- FEEDBACK — Comentarios y opiniones
- INVOICE — Facturas y documentos
- ORDER — Órdenes de compra
- PAYMENT — Métodos de pago
- REFUND — Reembolsos
- SHIPPING — Envíos
- SUBSCRIPTION — Suscripciones

Descripción del preprocesamiento aplicado

El preprocesamiento se realizó en los siguientes pasos, aplicados a cada solicitud del dataset:

Pasos aplicados

- **Eliminación de placeholders:** Se removieron patrones como {{Order Number}}, {{Website URL}} usando expresiones regulares.
- **Conversión a minúsculas:** Todo el texto se convirtió a minúsculas para uniformidad.
- Eliminación de caracteres especiales: Se eliminaron números, signos de puntuación y símbolos.
- **Tokenización:** El texto se dividió en palabras individuales (tokens).
- Eliminación de stopwords: Se removieron palabras comunes en inglés (como 'the', 'is', 'a') usando NLTK.
- **Stemming:** Se utilizó el Porter Stemmer de NLTK para reducir las palabras a su raíz. Por ejemplo: cancelling → cancel

Justificación de Stemming

Se usó stemming en lugar de lematización porque el Porter Stemmer funciona mejor con los gerundios y verbos conjugados que aparecen en el dataset. Aunque a veces las palabras resultantes no son palabras reales, por ejemplo, **purchase** se convierte en **puchas**, el modelo igual aprende a reconocer patrones entre palabras que tienen la misma raíz.

Construcción del Vocabulario

Después del preprocesamiento se construyó el vocabulario con todas las palabras únicas. Se aplicó un filtro para eliminar palabras que aparecen menos de 3 veces en todo el dataset, ya que estas suelen ser errores de tipeo muy raros que no aportan información útil al modelo. El vocabulario final quedó con 645 palabras únicas.

Explicación matemática del algoritmo Naïve Bayes, Laplace Smoothing y suma de logaritmos.

Naive Bayes

Naive Bayes es un clasificador probabilístico basado en el Teorema de Bayes. Para clasificación de texto, se utiliza la versión Multinomial, que trabaja con frecuencias de palabras.

Dado un texto con palabras w_1, w_2, ..., w_n, se calcula la probabilidad de que pertenezca a cada clase c y se elige la clase con mayor probabilidad:

$$c^* = \text{argmax } P(c) \times \prod P(w_i \mid c)$$

Probabilidad a Priori P(c)

Es la probabilidad de que una solicitud cualquiera pertenezca a la clase c, calculada como:

$$P(c) = \text{número de documentos de clase } c \text{ / total de documentos}$$

Laplace Smoothing

Para evitar que palabras no vistas en el entrenamiento generen una probabilidad de cero, se aplica Laplace Smoothing con α=1:

$$P(w \mid c) = (\text{conteo}(w, c) + 1) / (\text{total_palabras}(c) + |V|)$$

Donde |V| es el tamaño del vocabulario. Esto garantiza que ninguna palabra tenga probabilidad cero.

Suma de Logaritmos

El producto de muchas probabilidades pequeñas puede causar underflow numérico (el número se vuelve tan pequeño que la computadora lo redondea a cero). Para evitarlo, se trabaja con logaritmos y se suman en lugar de multiplicar:

$$\text{score}(c) = \log P(c) + \Sigma \log P(w_i \mid c)$$

La clase predicha es la que tenga el score más alto (menos negativo).

Evaluación y Métricas

K-Folds Cross Validation

Se implementó K-Folds Cross Validation con K=5 de forma manual. El dataset se dividió en 5 partes iguales de 5,374 instancias cada una. En cada iteración, una parte se usa para prueba y las restantes 4 para entrenamiento. Se promedian las métricas de los 5 folds.

Fold	Exactitud	Observación
Fold 1	99.20%	Muy alta
Fold 2	99.26%	Muy alta
Fold 3	99.24%	Muy alta
Fold 4	99.05%	Muy alta
Fold 5	98.90%	Muy alta
Promedio	99.13%	Varianza muy baja

La varianza entre folds es muy baja (menos de 0.4%), lo que indica que el modelo es estable y no depende de qué datos le toquen en cada iteración.

```
PS C:\Users\KAPALACIOS\UNIVERSIDAD\Proyecto 1 - Karla Palacios> cd src
PS C:\Users\KAPALACIOS\UNIVERSIDAD\Proyecto 1 - Karla Palacios\src> python kfolds.py
Total de datos: 26872
Tamaño de cada fold: 5374
Corriendo 5-Folds...

Fold 1: Exactitud = 0.9920
Fold 2: Exactitud = 0.9926
Fold 3: Exactitud = 0.9924
Fold 4: Exactitud = 0.9905
Fold 5: Exactitud = 0.9890

Exactitud promedio: 0.9913
```

Definición de Métricas

- **Precisión:** De todas las veces que el modelo predijo una clase, ¿cuántas veces acertó?

  Precisión = TP / (TP + FP)
- **Recall:** De todos los casos reales de una clase, ¿cuántos detectó el modelo?
  Recall = TP / (TP + FN)
- **F1-Score:** Media armónica entre Precisión y Recall.

F1 = 2 × (Precisión × Recall) / (Precisión + Recall)

- **Accuracy global:** Porcentaje total de predicciones correctas sobre todos los datos de prueba.
- **Macro F1:** Promedio del F1-Score de todas las clases, sin importar el tamaño de cada clase.

Resultados por Clase

Clase	Precisión	Recall	F1-Score
ACCOUNT	99.75%	99.75%	99.75%
CANCEL	100.00%	99.02%	99.51%
CONTACT	100.00%	99.52%	99.76%
DELIVERY	97.91%	92.14%	94.94%
FEEDBACK	99.52%	100.00%	99.76%
INVOICE	99.75%	99.50%	99.63%
ORDER	96.75%	98.98%	97.85%
PAYMENT	99.28%	99.05%	99.17%
REFUND	99.44%	99.26%	99.35%
SHIPPING	97.17%	99.76%	98.45%
SUBSCRIPTION	99.47%	99.47%	99.47%

```
PS C:\Users\KAPALACIOS\UNIVERSIDAD\Proyecto 1 - Karla Palacios\src> python metricas.py
Clase            Precisión     Recall   F1-Score
ACCOUNT             0.9975     0.9975     0.9975
CANCEL              1.0000     0.9902     0.9951
CONTACT             1.0000     0.9952     0.9976
DELIVERY            0.9791     0.9214     0.9494
FEEDBACK            0.9952     1.0000     0.9976
INVOICE             0.9975     0.9950     0.9963
ORDER               0.9675     0.9898     0.9785
PAYMENT             0.9928     0.9905     0.9917
REFUND              0.9944     0.9926     0.9935
SHIPPING            0.9717     0.9976     0.9845
SUBSCRIPTION        0.9947     0.9947     0.9947
Exactitud global:              0.9890
Macro F1:                      0.9888

MATRIZ DE CONFUSION

                ACCOUNT      CANCEL     CONTACT    DELIVERY    FEEDBACK     INVOICE       ORDER     PAYMENT      REFUND   SHIPPINGSUBSCRIPTION
     ACCOUNT       1180           0           0           0           0           0           0           3           0           0           0
      CANCEL          0         202           0           0           0           0           1           0           1           0           0
     CONTACT          1           0         414           0           1           0           0           0           0           0           0
    DELIVERY          0           0           0         375           0           0          22           0           0          10           0
    FEEDBACK          0           0           0           0         418           0           0           0           0           0           0
     INVOICE          0           0           0           0           1         399           0           0           0           1           0
       ORDER          0           0           0           5           0           1         775           0           1           1           0
     PAYMENT          2           0           0           1           0           0           1         416           0           0           0
      REFUND          0           0           0           2           0           0           1           0         537           0           1
    SHIPPING          0           0           0           0           0           0           1           0           0         412           0
SUBSCRIPTION          0           0           0           0           0           0           0           0           1           0         188
PS C:\Users\KAPALACIOS\UNIVERSIDAD\Proyecto 1 - Karla Palacios\src>
```

Matriz de Confusión Análisis

La Matriz de Confusión muestra que la mayoría de las clases se clasifican perfectamente. Sin embargo, hay dos confusiones notables:

- **DELIVERY vs ORDER:** 22 solicitudes de DELIVERY fueron clasificadas como ORDER. Esto ocurre porque los clientes suelen escribir 'where is my order' en lugar de 'where is my delivery', por lo que el modelo asocia ese lenguaje con la categoría ORDER.
- **DELIVERY vs SHIPPING:** 10 solicitudes de DELIVERY fueron clasificadas como SHIPPING. Tiene sentido, ya que ambas categorías hablan de paquetes y envíos y comparten vocabulario similar.

Las categorías CANCEL, CONTACT y FEEDBACK son las que el modelo predice mejor, con casi 100% en todas las métricas. Las categorías con más confusión son DELIVERY, ORDER y SHIPPING por la similitud en el vocabulario que usan los clientes.

Diagramas

Arquitectura de la solución

Imagen No.1 Arquitectura de solución

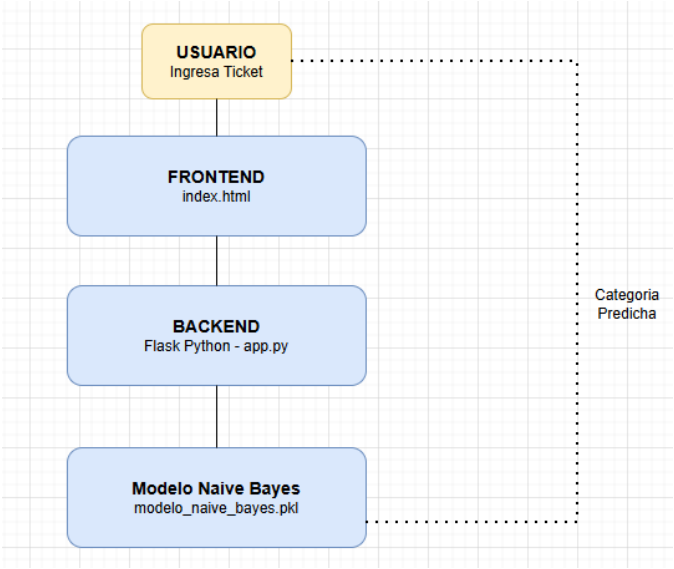

Fuente: Propia

Diagrama de caso de uso

Imagen No.2 Arquitectura de solución

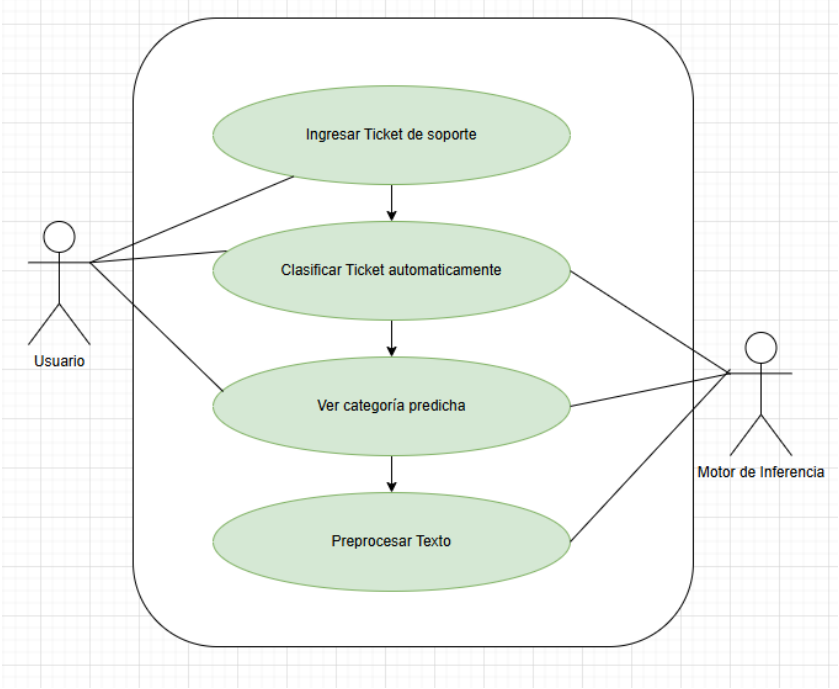

Fuente: Propia

Diagrama de Flujo General

Imagen No.3 Diagrama de Flujo General

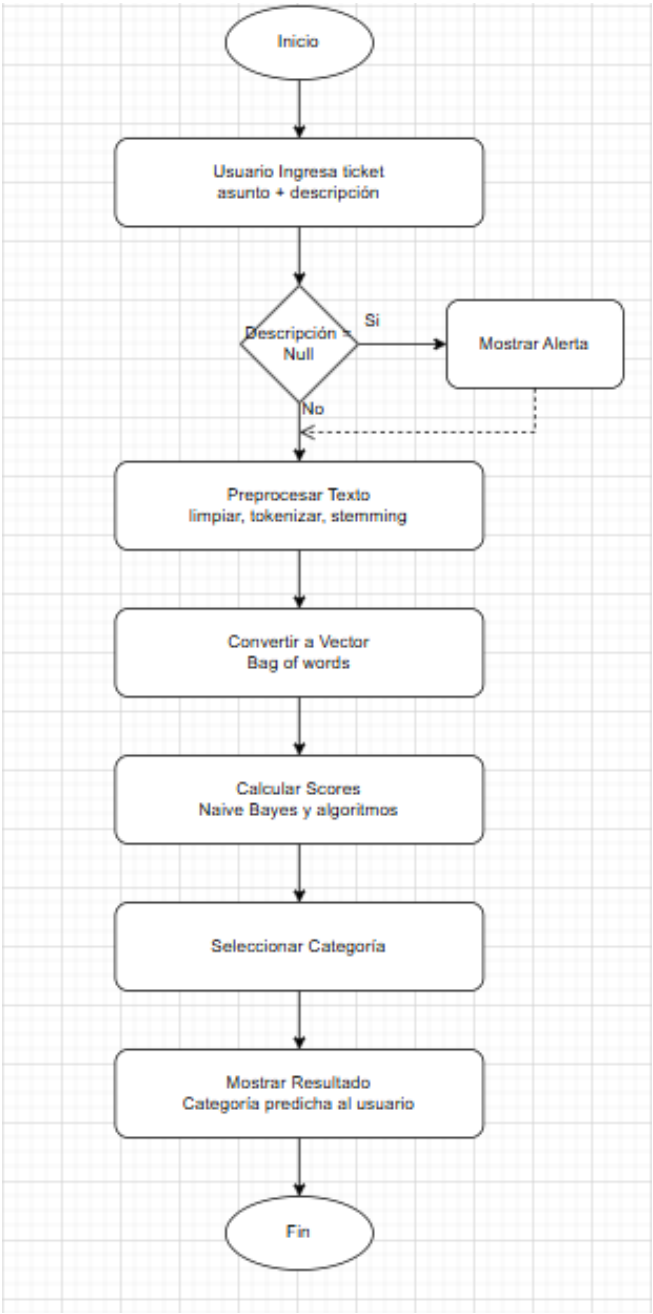

Fuente: Propia

Diagrama de Componentes

Imagen No.4 Diagrama de Componentes

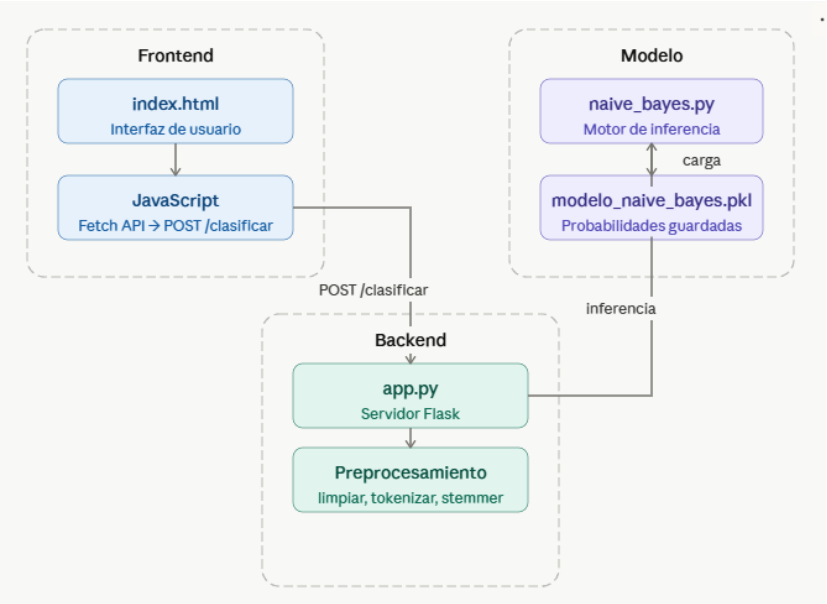

Fuente: Propia

Diagrama de Secuencias

Imagen No.5 Diagrama de Secuencias

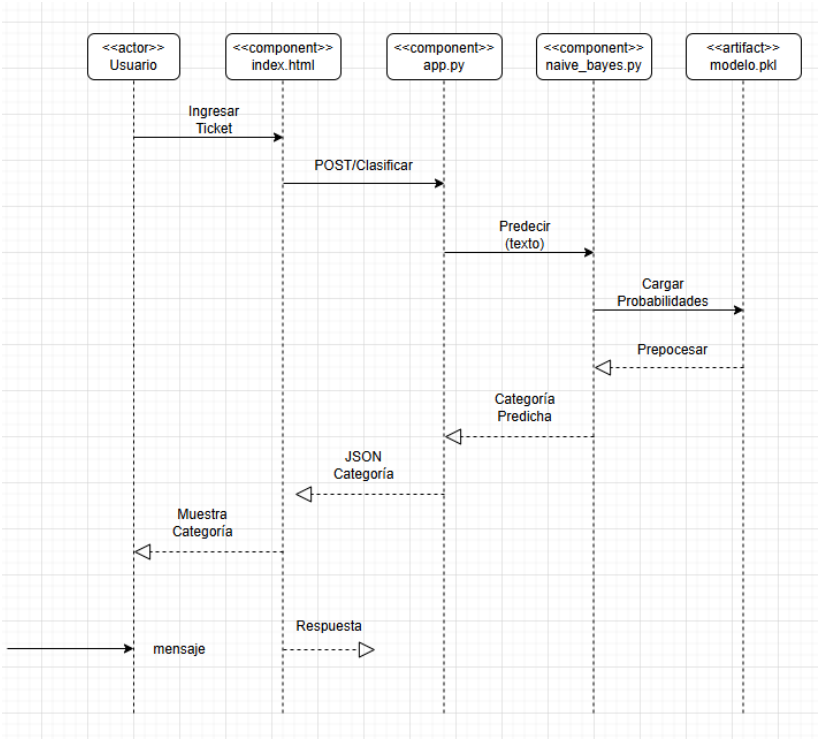

Fuente: Propia

Página Principal

Vista inicial

Imagen No.6 Modal para ingresar ticket

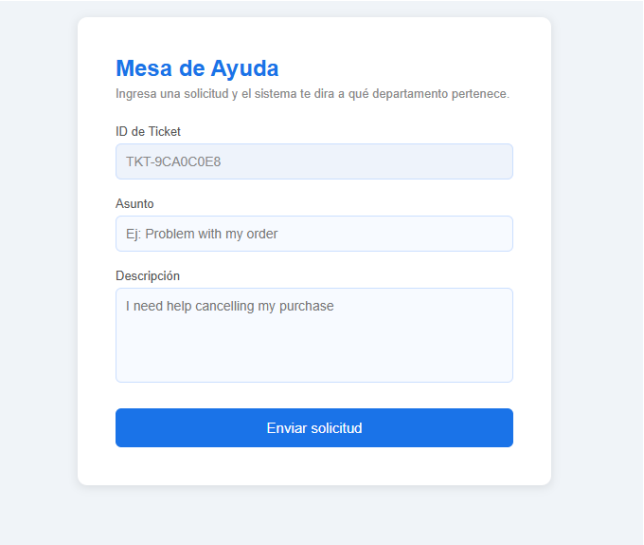

Fuente: Propia

Se puede probar con Order, Refund, Delivery, Account

Imagen No.7 Resultado de Clasificación

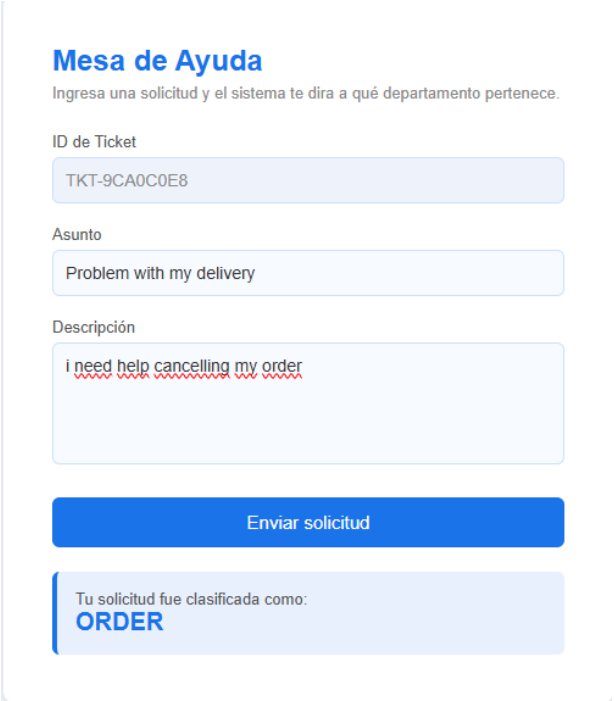

Fuente: Propia

Terminal

Modelo Entrenado

Imagen No.8 Modelo

```
PS C:\Users\KAPALACIOS\UNIVERSIDAD\Proyecto 1 - Karla Palacios\src> python guardar_modelo.py
Entrenando modelo con todo el dataset...
Modelo entrenado!
Modelo guardado en: modelo/modelo_naive_bayes.pkl
Modelo cargado correctamente
Clases disponibles: ['ACCOUNT', 'CANCEL', 'CONTACT', 'DELIVERY', 'FEEDBACK', 'INVOICE', 'ORDER', 'PAYMENT', 'REFUND', 'SHIPPING', 'SUBSCRIPTION']
PS C:\Users\KAPALACIOS\UNIVERSIDAD\Proyecto 1 - Karla Palacios\src>
```

Fuente: Propia

Métricas

Imagen No.9 Métricas

```
PS C:\Users\KAPALACIOS\UNIVERSIDAD\Proyecto 1 - Karla Palacios\src> python metricas.py
Clase            Precisión     Recall   F1-Score
ACCOUNT             0.9975     0.9975     0.9975
CANCEL              1.0000     0.9902     0.9951
CONTACT             1.0000     0.9952     0.9976
DELIVERY            0.9791     0.9214     0.9494
FEEDBACK            0.9952     1.0000     0.9976
INVOICE             0.9975     0.9950     0.9963
ORDER               0.9675     0.9898     0.9785
PAYMENT             0.9928     0.9905     0.9917
REFUND              0.9944     0.9926     0.9935
SHIPPING            0.9717     0.9976     0.9845
SUBSCRIPTION        0.9947     0.9947     0.9947
Exactitud global:              0.9890
Macro F1:                      0.9888

MATRIZ DE CONFUSION

                ACCOUNT    CANCEL    CONTACT   DELIVERY   FEEDBACK   INVOICE     ORDER   PAYMENT    REFUND  SHIPPINGSUBSCRIPTION
     ACCOUNT       1180         0          0          0          0         0         0         3         0         0          0
      CANCEL          0       202          0          0          0         0         1         0         1         0          0
     CONTACT          1         0        414          0          1         0         0         0         0         0          0
    DELIVERY          0         0          0        375          0         0        22         0         0        10          0
    FEEDBACK          0         0          0          0        418         0         0         0         0         0          0
     INVOICE          0         0          0          0          1       399         0         0         0         1          0
       ORDER          0         0          0          5          0         1       775         0         1         1          0
     PAYMENT          2         0          0          1          0         0         1       416         0         0          0
      REFUND          0         0          0          2          0         0         1         0       537         0          1
    SHIPPING          0         0          0          0          0         0         1         0         0       412          0
SUBSCRIPTION          0         0          0          0          0         0         0         0         1         0        188
PS C:\Users\KAPALACIOS\UNIVERSIDAD\Proyecto 1 - Karla Palacios\src>
```

Fuente: Propia